


1. Artificiell intelligens (AI) är det yttre skalet för Maskininlärningen (ML) som i sin tur är skalet till Djupinlärning (DL). Se bild nedan.

AI är det helhetsbegrepp som man normalt använder för en dator (el motsv) som tar egna beslut baserat på input.

ML är en metod att lära datorn att hitta mönster i datamängder och därifrån skapa algoritmer (programmera sig själv). Ju mer data desto bättre (mer korrekt) beslut.

DL är det djupaste analysmetoden av ML där man försöker efterlikna den mänskliga hjärnan. Är mycket tyngre att driva (träning, etc). Det är också enklare att förstå ML modellerna än DL som blir mer att betrakta som en svart låda.



(Här minns jag ett uttalande från Nobelpristagaren (i AI) Geoffrey Hinton där han svarade en reporter som påstod att "vi har ju skapat AI (neurala nätverk) så vi borde kunna kontrollera det också" med att vi har skapat metoden men vad det neurala AI kommer fram till kan vi inte kontrollera. Lite 'Skynet' (Terminator filmen) trots allt.)

2. En lösning skulle kunna vara att använda k-delad korsvalidering i 5 delar på träningsdatan. För varje iteration beräknas RMSE. Den modell som har lägst RMSE är den hon väljer. (sid 30)
3. Regressionsproblem – prediktera en kontinuerlig beroende variabel (y) m h a oberoende variabler (x), dvs söker sambandet mellan flera förklarande ingångsvariabler med en beroende utgående variabel. Modeller som används kan vara (sid 109);
 - Linjär regression
 - Ridge regression (L2)
 - Lasso regression (L1)
 - Elastic net (kombo av de två ovan)
 - Support Vector Machines (SVM)
 - Beslutsträd
 - Ensemble learning
 - Random forest

Områden;

Prognoser (predict) samband som huspriser, bilpriser, hälsovård (mm) baserat på objektens egenskaper som storlek, geografisk plats, blodtryck (mm).

4. Optimeringsalgoritm, linjär regression

$$Y = \beta_0 + \beta_1 X + \epsilon$$
 (sid 111, 122)
 Y – beroende variabel, målvariabel
 X – oberoende variabel, regressor
 β_0, β_1 – fixa men okända parametrar (konstant, lutning)
 ϵ – residual / felterm

5. Utvärderingsmått för regressionsmodeller
Medelavstånd från observerade värdena (y) medelavstånd från de predikterade värdena ($\hat{y}$) (räta linjen). Hur mycket fel har vi. (106, 33)

6. 151 Klassificeringsproblem – till skillnad från regression, ger utdatan diskreta värden (binär ja/nej, man/kvinna – binär klassificering. Traktor, bil, moped – multiklass klassificering.

Modeller som används (166, 168);
Logistisk regression (booleansk, binär output, 1/0)
Support Vector Machines
Beslutsträd
Ensemble learning
Random forest

Tillämpningar (exempel)
E-post – spamanalys
Bildanalys/tolkning (Röntgenbilder, vägskyltar)
'Churn' analys – stannar kunden el ej

7. Ett utvärderingsmått som visar hur väl en modell fungerar genom att jämföra sanna med predikterade värden. Resultatet presenterar som en matris (exempel sid 156). I detta exempel har t ex klass 2 klassats som klass 1 12 ggr, klass 5 15 ggr. Diagonalen i matrisen (vänster hörn högst upp till höger längs ned) visar de gånger det klassats rätt.
Ett binärt klassificeringsproblem har en matris 2×2 där diagonalen benämns True Positive, True Negative för de korrekta klassningarna (sid 155, bild 4.2) därtill kommer False negative (klassat en sann som falsk) och False positive (klassat negativ som positiv).
8. Precision = True Positive / (True Positive + False Positive), kort och gott; Förhållandet mellan rätt klassning och totala antalet klassningar. Hur rätt hade modellen gällande True positive som var helt korrekta (svar mellan 0 – 1, 0 – 100%, inte HELT noll dock). Hög precision, modellen har rätt i klassifiering men missar en del positiva (159)
9. Recall = True Positive / (True Positive + False Negative), förhållandet mellan korrekta positiva predikteringar och antalet egentliga positiva fall som tolkades felaktigt negativt. Inverse av precision (se kurva sid 160).

Både Precision o Recall kan styras med threshold inställning, balans mellan dessa två benämns F1-score (sid 162, 214).
10. Jag lutar åt Julia då hon värdesätter färgen röd före de två andra färgerna. Färgerna som så har ingen skillnad, inget värde mot varandra (nominal) men på fest blir man vackrast (värderad) med en röd skjorta.

11. Hyperparametrar sätts av användaren innan körning i koden (hur vi lär) medans parametrar sätts (vad vi lärt oss) under körning i den färdiga modellen (35).
Om modellen får anpassa/optimera sina egna hyperparametrar finns risk för överanpassning (modellen ser till att fungera fantastiskt mot träningsdatan men felar på valideringen).
GridSearch kan användas för att hitta de optimala hyperparametrarna.
12. Bra bilder på sidan 25.
En överanpassad modell (overfitting) är för komplex och har anpassat (memorerat) sig fullt ut på träningsdatan men fallerar på validering. Åtgärd för att motverka överanpassning är regularisering (L1/L2/Elastic net). Regularisering – ta bort / justera data som avviker för mycket.
En underanpassad modell (underfitting) är för enkel och har inte hittat strukturen i datasetet.
När på samma resultat (y) oavsett värde på x.
13. Multiklass klassificeringar med binär klassificeringsmodell (154)
One-vs-rest; En modell tränas per klass. T ex modeller för Bil, cykel, båt (3 st)
Klassificering av ny bild körs genom alla tre modellerna och den klass med högst igenkännings score vinner.

One-vs-one; En modell för varje par av (kombination) klasser (N) enl formeln $(N \times (N-1) / 2)$.
Samma dataset (Bil, cykel, båt) ger tre modeller i skillnader mellan de tre möjliga kombinationerna (bil – cykel, bil – båt, cykel – båt). Klassificering av ny bild fungerar så att varje modell ger sin poäng. Flest poäng – (vinner) tolkningen.

Använder vi en binär klassificeringsmodell för multiklass så sköter scikit-learn automatiskt köra OvR el OvO åt oss.
14. Motverka överanpassning, justera bort avstickande data (brus) som förstör helheten och modellens enkelhet.
15. The Bias Variance Trade-off (128)
Bias – felaktiga modellantaganden t ex antagande att datan är linjär men den är kvadratisk, modellen är för enkel och missar relevanta samband mellan variabler – leder till underanpassning/underfitting.
Variance – Modellen är för flexibel (komplex), ser/lär mönstret och tar även bruset. Små förändringar i träningsdata kan leda till att modellen för hög varians – kan leda till överanpassning/overfitting.
Irreducerbart fel – Slumpmässighet i datat
16. Genom att öka en modells komplexitet så ökar vi dess varians men minskar bias, minskar vi dess komplexitet – minskar variansen men ökar bias. Därför är inte en komplex modell alltid bättre, ökningen av varians kan kosta mer än vad minskningen i bias kostar. Detta är själva trade-off:en i Bias Variance Trade-off. (129)

17. 107,33

För att hitta de optimala β parametrarna/värdena använder vi ett mått på hur fel modellen har. Vi använder Mean Squared Error (MSE) – medelvärdet av skillnad mellan predikterade $\hat{y}(i)$ och verklighet $y(i)$ i kvadrat. (Se formel, utan roten-ur och graf sid 34).

18. Skillnaden mellan MSE och RMSE är att vid RMSE tar man roten ur MSE för att på så vis få tillbaka enheten (kr, liter) till originalenhet. Svårt att förstå t ex kr^2 . T ex MSE på 10000 betyder det att modellen felar med 10000 kr^2 , RMSE på 100 kr är lättare. MSE är mer för datorer och RMSE för människan.

19. Övervakad ML – Modellen lär sig från exempel där rätt svar finns. Data: X & y (y en funktion av X)
M h a Regression, klassifiering
Oövervakad ML – Modellen hittar mönster utan facit. Data: X
M h a Dimensionsreducering, klustering

20. Prediktionsintervall – beskriver osäkerheten för ett enskilt framtida värde/observation. Tar hänsyn till både osäkerheten i modellen och den naturliga spridningen i datat. (Osäkerhet= Fel i modellens position + brus)

Konfidensintervall – beskriver osäkerheten kring det genomsnittliga värdet (y) för en viss grupp med egenskapen x. (Osäkerhet= Fel i modellens position)

Prediktionsintervallet är bredast då det gäller ett enskilt värde som också måste ta hänsyn till brus/avvikelser.

Konfidensintervallet gäller en grupp där (medel)data redan finns för gruppen.

Självutvärdering

1. Min största utmaning har varit tiden för självstudier, tester i o m att jag får ofta vara barnbarnsvakt till en 6 åring som det är mycket fart i. Detta samtidigt som man har ett jobb och resor. Det blir trångt men man får försöka leverera ändå. Jag har också haft fördelen att jag redan har programmeringstänket. Jag stannar inte här utan nu har jag fått grundkänslan för att fortsätta utveckla i Python, vilket känns väldigt bra! Jag har också haft enorm tur att sluppit krockar med ordinarie arbetet och kunnat delta närmast 100%.
2. Jag kommer inte hinna att leverera i tid (har jag insett) och därför nöjer jag mig med ett Godkänt.
3. Du har gjort ett väldigt bra jobb och det har varit både intressant och roligt varje sammankomst.